

Part B. Calculation Exercises

Ex1.

$$(D-1): [1, 0, 1, 1, 0]$$

$$(D-2): [0, 1, 1, 1, 0]$$

$$(D-3): [1, 0, 0, 1, 1]$$

Ex2.

$$t_j(t, D) = \frac{c(t, d)}{\sum_t c(t, d)}$$

$$t_j(cat, D_1) = \frac{1}{3}$$

$$t_j(eats, D_1) = \frac{1}{3} \quad t_j(fish, D_1) = \frac{1}{3}$$

$$\Rightarrow \sum_t t_j(t, D_1) = 1.$$

Ex3

$$N=3, \quad idf(t) = \log \frac{N}{df(t)}$$

$$idf(cat) \approx 0,4055$$

$$idf(log) \approx 1,0986$$

$$idf(eats) \approx 0,4055$$

$$idf(fish) \approx 0$$

$$idf(likes) \approx 1,0986$$

Ex4.

$$t_j = idf(cat) = t_j(cat)$$

$$t_j - idf(cat, D_1) = t_j(cat, D_1) \times idf(cat) = \frac{1}{3} \cdot 0,4055 \approx 0,1352$$

$$t_j - idf(eats, D_1) = \frac{1}{3} \cdot 0,4055 \approx 0,1352$$

$$t_j - idf(fish, D_1) = \frac{1}{3} \cdot 0 = 0, \text{ đó hiển nhiên vì } fish = 0 \text{ (idf(fish) = 0, } t_j - idf \text{ dựa vào cả } t_j \text{ và idf.)}$$

Ex5.

$$\cos(x, y) = \frac{x \cdot y}{\|x\| \cdot \|y\|} = \frac{2}{\sqrt{6}}$$

* Cosine similarity đo độ khớp giữa các tham số do góc giữa hai vector

- khi chuẩn hóa bằng vector, thiếu 1 tam làm góc lệch 35.26°

Ex 6.

1. D_1 có similarity cao nhất
2. D_3 có similarity thấp nhất
3. medical và fire image có idg thấp nhất
4. Bỏ idg, dùng convectors thì ranking không đổi

Part C. Prediction before Experiment.

Predict 1: Corpus 30K doc $\rightarrow$ khoảng 300.000 - 400.000 terms

Predict 2: - TF-IDF Matrix sẽ sparse
- tỉ lệ zero entries $\geq 90\%$

Predict 3: không

Part E. Core Implementation

- khác nhau ở công thức: sklearn dùng smooth IDF $\Rightarrow$ tiết kiệm 0
- khác nhau ở normalization: sklearn áp dụng L2 Norm
- Convention: sklearn dùng regex, tự thực hiện dùng `split('')`.
- implementation: tự code dùng numpy, sklearn dùng matrix thưa

Part F. Ex 2

9.5. Trả lời câu hỏi

1. Lowercase làm giảm bất thường từ điển: $A \rightarrow a$
2. Loại bỏ, xóa stop words $\rightarrow$ một ngữ nghĩa
3. Làm một ngắt quãng câu, biểu hiện cảm xúc, tiền tệ, email, hashtag, ...
4. Minimal tạo ra sparse matrix nhất, do
5. Pipeline B tốt cho search nhất, dễ nhanh và tốt, tự nhiên 1 vài thuật toán pipeline C xử lý tốt hơn
6. Không nhất thiết. Search tốt cần vocab từ ngữ: đủ gọn và đủ nghĩa

Part I. Error Analysis

- 2 Query có kết quả tốt:

+ Query: "Medical image classification"

• Expected relevant documents [0, 6]

• Retrieved documents: Doc 6 and doc 0

→ Doc 6 đứng đầu vì chứa cả 3 terms

→ Các từ medical, image, classification tổng hợp cao vì id.

→ Có lexical overlap 100%.

→ không, cả 2 relevant doc đều ở đầu

→ Tuy vậy, này thật công

+ Query: "deep learning health care"

• Expected relevant documents [3, 4, 5, 6]

• Retrieved documents: Doc 3, 4, 5, 6

→ Doc 3 đứng đầu vì chứa cả 3 terms

→ "deep learning" xuất hiện thường xuyên trong corpus, healthcare có IDF Cao

→ không doc nào bị bỏ sót

→ kết quả khá tốt

- 2 Query kết quả kém

+ Query: "transformation language model"

• Expected relevant documents [2, 5]

• Retrieved documents: Docs 2, 5, 7, 1

→ doc 2 đứng đầu, do chứa cả cụm

→ Các toàn bộ từ đều đóng góp nhiều

→ Có lexical overlapping nhưng doc 5 bị hạn chế, thiếu language

→ Doc 5 bị đẩy xuống và bỏ sót

→ Fail do từ thiếu từ

Query: "natural language processing".

Expected relevant documents [1, 2, 7]

Retrieved documents: Doc 7, 1, 5, 2

→ 7, 1 cũng như 1 do được cả cùng

→ Tập hợp các từ đều có cùng số 'TF-IDF' cân bằng

→ Có over lexical overlapping với Doc 1 và 7, doc 2 gần như bằng 0

→ Doc 2 bị đẩy xuống rất dưới. Similarity thấp

→ TF-IDF Fail: TF-IDF số khớp, thay vì hiểu nghĩa viết tốt

⊙ Failure case quan trọng nhất: Query "Natural language processing" với

Doc 2.

→ TF-IDF ^{ở mô hình} biểu diễn số, thay vì chữ. mô hình không hiểu được viết tốt.

Tuy nhiên về mặt ngữ nghĩa, chúng không tương tự tự. Nó coi NLP khác natural language processing.

Part I From Failure to the next NLP presentation

- Để giải quyết vấn đề về similarity nghĩa, có thể sử dụng context hay ngữ cảnh.